

Relatório Classificação de Imagens Usando Redes Neurais Convolucionais

Disciplina: Tópicos em Aprendizado de Máquina

Aluno: Gustavo Emanuel

Professora: Aurora Trinidad Ramirez Pozo

Introdução ao problema e ao dataset escolhido

Os tumores cerebrais são massas formadas por células anormais no cérebro. Dada a rigidez do crânio, qualquer crescimento anormal nesse espaço confinado pode gerar aumento da pressão intracraniana, levando a danos cerebrais severos e colocando a vida do paciente em risco. Esses tumores podem ser benignos ou malignos, sendo fundamental identificá-los precocemente para possibilitar a escolha do tratamento mais adequado.

A detecção e a classificação precoce de tumores cerebrais constituem um campo crucial da pesquisa em imagem médica. Com o avanço das técnicas de aprendizado profundo, especialmente com redes neurais convolucionais (CNNs), novas abordagens têm sido desenvolvidas para melhorar a precisão diagnóstica utilizando imagens de ressonância magnética (MRI).

Para essa tarefa, foi utilizado um dataset composto por três bases diferentes: Figshare, SARTAJ e Br35H. Após verificação da qualidade dos dados, identificou-se que a classe *glioma* da base SARTAJ continha imagens mal categorizadas. Por esse motivo, as imagens dessa classe foram substituídas por imagens mais confiáveis da base Figshare.

O dataset final contém 7023 imagens de ressonância magnética cerebral, distribuídas em quatro classes:

- Glioma
- Meningioma
- Sem tumor (no tumor)
- Pituitário

As imagens da classe "sem tumor" foram extraídas especificamente da base Br35H. Um ponto importante é que as imagens possuem tamanhos variados. Para garantir uma melhor performance do modelo, é necessário realizar um pré-processamento que inclui o redimensionamento e a remoção de margens extras.

Metodologias Utilizadas para Pré-processamento e Modelagem

Pré-processamento dos Dados

Para garantir um bom desempenho dos modelos de deep learning, foi realizado um pré-processamento eficaz das imagens de ressonância magnética cerebral (MRI). O conjunto de dados apresenta imagens de diferentes tamanhos e proporções, portanto, uma das etapas iniciais foi o redimensionamento das imagens para

128x128 pixels. Isso padroniza as entradas para as redes neurais convolucionais (CNNs), facilitando o aprendizado e a convergência dos modelos.

Além disso, foram aplicadas técnicas de normalização, como o redimensionamento dos valores dos pixels para um intervalo entre 0 e 1, o que contribui para a estabilidade durante o treinamento. Também foram utilizadas transformações de data augmentation para aumentar a variabilidade do conjunto de treinamento e reduzir o overfitting, como rotações e flips horizontais.

Modelagem com Redes Convolucionais (CNN)

1. Rede CNN Simples

Foi implementada uma CNN do zero com uma arquitetura leve e eficiente, composta por:

- Duas camadas convolucionais com ReLU e max pooling;
- Camadas totalmente conectadas (fully connected) ao final;
- Dropout para reduzir o overfitting.

Essa rede serviu como ponto de partida para comparação com arquiteturas mais profundas.

2. LeNet

A arquitetura inspirada na clássica LeNet-5, adaptada para imagens RGB de 128x128, inclui:

- Duas camadas convolucionais seguidas de ReLU e pooling;
- Flatten das ativações seguido por camadas fully connected;
- Uma saída com 4 neurônios correspondendo às classes;
- Treinada por 15 épocas.

LeNet demonstrou ser eficaz para tarefas mais simples, oferecendo desempenho razoável com baixo custo computacional.

3. VGG-Inspired CNN

Foi também testada uma arquitetura inspirada na VGG, com blocos convolucionais mais profundos:

- Três blocos convolucionais com múltiplas camadas (Conv + BatchNorm + ReLU + MaxPool);
- Aumento progressivo do número de filtros ($32 \rightarrow 64 \rightarrow 128$);
- Camadas densas no final com 512 neurônios e Dropout;
- Essa rede foi treinada por 15-500 épocas, para realizar testes e buscar melhores resultados.

Resultados obtidos e análise das métricas de desempenho

1. Rede CNN Simples

A Rede CNN Simples apresentou desempenho significativamente superior às demais, com acurácia de 98%. Todas as classes foram classificadas com altíssima precisão, recall e F1-score, variando entre 0,95 e 1,00. Isso indica que a arquitetura construída foi altamente eficaz em capturar as características discriminativas das imagens de diferentes tipos de tumores.

A uniformidade nas métricas entre todas as classes mostra que o modelo teve bom balanceamento e foi robusto, sem favorecer ou negligenciar nenhuma das classes.

	precision	recall	f1-score	support
glioma	0.97	0.96	0.97	300
meningioma	0.96	0.95	0.96	306
notumor	0.99	1.00	0.99	405
pituitary	0.98	1.00	0.99	300
accuracy			0.98	1311
macro avg	0.98	0.98	0.98	1311
weighted avg	0.98	0.98	0.98	1311

2. LeNet

A LeNet, uma arquitetura clássica e simples, obteve acurácia geral de apenas 24%. Embora tenha apresentado um recall elevado para a classe glioma (0,96), indicando que conseguiu

identificar corretamente quase todos os casos dessa classe, a precisão foi muito baixa (0,24), o que revela um elevado número de falsos positivos.

As demais classes, especialmente *no tumor*, tiveram desempenho praticamente nulo (precisão, recall e F1 próximos de 0), evidenciando baixa capacidade de generalização da LeNet em problemas mais complexos e com múltiplas classes.

	precision	recall	f1-score	support
glioma	0.24	0.96	0.39	300
meningioma	0.35	0.02	0.04	306
notumor	0.00	0.00	0.00	405
pituitary	0.18	0.06	0.09	300
accuracy			0.24	1311
macro avg	0.19	0.26	0.13	1311
weighted avg	0.18	0.24	0.12	1311

3. VGG-Inspired CNN

Apesar de ser uma rede mais profunda e com maior capacidade de aprendizado, a VGG-Inspired obteve acurácia de 22%, semelhante ou até inferior à LeNet. Ainda que o *recall* da classe *no tumor* tenha sido o maior entre as classes (0,48), as demais apresentaram resultados fracos, com destaque para a classe *pituitary*, cuja revocação foi de apenas 0,06.

A baixa performance pode estar relacionada a hiperparâmetros inadequados, problemas de overfitting, ou mesmo necessidade de mais épocas de treinamento ou regularização.

	precision	recall	f1-score	support
glioma	0.11	0.12	0.12	300
meningioma	0.28	0.15	0.19	306
notumor	0.26	0.48	0.34	405
pituitary	0.23	0.06	0.09	300
accuracy			0.22	1311
macro avg	0.22	0.20	0.19	1311
weighted avg	0.22	0.22	0.20	1311

Discussão sobre os desafios enfrentados e possíveis melhorias para o modelo

Um dos principais desafios enfrentados neste trabalho foi o próprio uso de imagens, que exige não apenas grande capacidade computacional, mas também um tempo significativo de processamento. Para contornar essa limitação e acelerar o treinamento, todas as redes foram treinadas com o uso de GPU.

Mesmo após testes com até 500 épocas, a rede VGG não apresentou um desempenho satisfatório. Para melhorar seus resultados, algumas estratégias poderiam ser adotadas. Entre elas, destaca-se a aplicação de técnicas de pré-processamento mais avançadas, como equalização de histograma, remoção de ruído e padronização de contraste, que contribuem para melhorar a qualidade visual das imagens e facilitar a extração de padrões pela rede.

Além disso, a utilização de data augmentation, por meio de transformações como rotação, espelhamento, zoom, deslocamento e adição de ruído, pode aumentar a diversidade dos dados de treinamento. Isso ajuda a reduzir o overfitting e melhora a capacidade de generalização do modelo.

Por fim, o uso de validação cruzada e a busca por valores ideais de hiperparâmetros como taxa de aprendizado, número de filtros, número de épocas e taxa de dropout podem contribuir significativamente para o aprimoramento do desempenho da rede.